PREDIKSI TREN FREKUENSI, TREN SEVERITAS, DAN TREN TOTAL CLAIM PADA DATA SCIENCE COMPETITION MCF ITB 2026

kita bantai di mcf

1. **Andi Nabil Safaraz**
2. **Aulia Kemal Syah**
3. **Naufal Dzakirsyah**

DATA SCIENCE COMPETITION (DSC)

MATHEMATICAL CHALLENGE FESTIVAL

INSTITUT TEKNOLOGI BANDUNG

2026

LEMBAR PERNYATAAN ORSINALITAS DAN DEKLARASI PENGGUNAAN KECERDASAN BUATAN GENERATIF

Kami yang bertanda tangan di bawah ini:

Nama Tim : kita bantai di mcf

Nama Ketua Tim : Andi Nabil Safaraz

Nama Anggota Tim 1 : Aulia Kemal Syah

Nama Anggota Tim 2 : Naufal Dzakirsyah

Dengan ini menyatakan bahwa laporan yang kami sertakan dalam perlombaan Data Science Competition (DSC) MCF ITB 2026 merupakan hasil karya orisinal, tidak mengandung plagiarisme dari pihak manapun, dan belum pernah diikutsertakan dalam perlombaan lain.

Kami juga mendeklarasikan penggunaan kecerdasan buatan generatif (Generative AI) dalam proses penyusunan laporan ini. Model kecerdasan buatan generatif yang digunakan adalah sebagai berikut:

Nama Model: Sonnet 4.6, Gemini 3 Pro.

Pengembang Model: Anthropic, Google.

Kami menggunakan model kecerdasan buatan generatif tersebut untuk keperluan berikut:

Keperluan pembuatan dan debugging *code* (preprocessing, feature engineering, implementasi model, dan pipeline submission), penyusunan draf laporan ilmiah berdasarkan hasil analisis yang telah dilakukan tim, serta pencarian dan rekomendasi referensi jurnal yang relevan.

Kami menyatakan bahwa seluruh keluaran model model kecerdasan buatan generatif yang digunakan telah melalui proses peninjauan, verifikasi, dan pengolahan ulang oleh tim. Seluruh isi laporan yang

dikumpulkan merupakan hasil pemahaman, analisis, dan tanggung jawab kami sebagai peserta kompetisi.

Apabila di kemudian hari kami diketahui melanggar pernyataan ini, kami siap menerima konsekuensi yang telah ditetapkan oleh panitia MCF ITB 2026 berupa sanksi diskualifikasi dari perlombaan ini. Demikian pernyataan ini dibuat dengan sebenarnya, untuk digunakan sebagaimana mestinya.

Sleman, 15 Maret 2026

Yang menyatakan,

Andi Nabil Safaraz

ABSTRAK

Kata kunci: asuransi kesehatan, peramalan klaim, dekomposisi lokasi, Chronos-Bolt, Prophet, ensemble model, MAPE, winsorization

Industri asuransi kesehatan Indonesia menghadapi tekanan klaim yang signifikan, dengan total klaim jiwa nasional mencapai Rp 24,18 triliun pada 2024 dan kenaikan sebesar 25,5% pada semester pertama 2025 dibandingkan periode yang sama tahun 2024. Penelitian ini mengembangkan model peramalan untuk memprediksi Claim Frequency, Claim Severity, dan Total Claim asuransi kesehatan individu AXA Financial Indonesia untuk periode Agustus–Desember 2025, menggunakan data 4.627 klaim selama Januari 2024–Juli 2025.

Analisis eksploratori mengungkap heterogenitas signifikan antar lokasi rumah sakit: klaim Singapura berkontribusi 47,4% dari total nilai klaim meskipun hanya 22,2% dari frekuensi, dengan rata-rata severity Rp 110,3 juta/klaim — 3,2 kali lebih tinggi dari Indonesia. Untuk menangani heterogenitas ini, dikembangkan pendekatan dekomposisi berbasis lokasi geografis (LocationDecomp) menggunakan Amazon Chronos-Bolt dengan strategi kuantil yang disesuaikan per segmen: Indonesia (Q0,2), Singapura (Q0,4), dan Malaysia (Q0,3). Model akhir merupakan ensemble tiga komponen dengan bobot equal (1/3 masing-masing) antara LocationDecomp, Chronos-Bolt agregat, dan Prophet — dinamakan LocationDecomposed_Triple.

Penelitian ini juga menemukan bahwa winsorization P99 pada klaim individual merupakan preprocessing yang diperlukan, diverifikasi secara empiris: model pada data raw menghasilkan MAPE 8,479 dibandingkan 4,473 dengan winsorization. Model terbaik (LocationDecomposed_Triple) mencapai skor MAPE 4,45031 pada public leaderboard Kaggle, meningkat 12,7% dari baseline ChronosBlend (4,646). Prediksi menunjukkan tren penurunan moderat dengan rata-rata Total Claim Rp 10,6 miliar/bulan untuk periode Agustus–Desember 2025.

DAFTAR GAMBAR

Gambar 1. Tren Frekuensi Klaim, Severitas, dan Total Nominal Klaim (Januari 2024–Juli 2025) 6

Gambar 2. Distribusi Tipe Perawatan: Proporsi, Jumlah Klaim, Rata-rata, dan Distribusi Nominal 7

Gambar 3. Outlier, Anomali, Tren Bulanan, dan LOS 8

Gambar 4. Cashless vs Reimburse 9

Gambar 5. Cashless vs Reimburse x Tipe Perawatan 10

Gambar 6. Distribusi Biaya RS per Plan Code dan Lokasi 11

Gambar 7. Frekuensi dan Total Biaya Klaim Berdasarkan Usia, Plan Code, Gender..... 12

Gambar 8. Total Biaya Top 10 ICD vs Kelompok Usia dan Rata-rata Biaya per Lokasi 13

Gambar 9. Visualisasi Data Historis dan Hasil Proyeksi Model LocationDecomposed_Triple (Agustus–Desember 2025) 15

DAFTAR ISI

ABSTRAK i

DAFTAR GAMBAR ii

DAFTAR ISI iii

BAB I PENDAHULUAN 1

1.1 Latar Belakang 1

1.2 Rumusan Masalah 2

1.3 Tujuan 3

BAB II METODOLOGI 3

2.1 Pemilihan Model 3

2.1.1 Prophet 3

2.1.2 Amazon Chronos-Bolt 4

2.2 Feature Engineering 4

2.2.1 Feature Engineering Tingkat Klaim Individual 4

2.2.2 Deret Waktu Bulanan 5

2.2.3 Feature Engineering Time Series 5

2.2.4 Dekomposisi Lokasi Geografis (LocationDecomp) 5

BAB III HASIL DAN PEMBAHASAN 6

3.1 Exploratory Data Analysis 6

3.1.1 Statistik Deskriptif dan Tren Deret Waktu 6

3.1.2 Analisis Tipe Perawatan dan Lama Penginapan 7

3.1.3 Analisis Cashless vs Reimburse 9

3.1.4 Analisis Lokasi Rumah Sakit 10

3.1.5 Analisis Demografi dan Diagnosis ICD 11

3.2 Machine Learning Training 12

3.2.1 Komponen Model Dasar (Base Learners) 13

3.2.2 Dekomposisi Geografis (LocationDecomp) 13
3.2.3 Arsitektur Final 13
3.3 Hasil Prediksi 14

BAB IV PENUTUP 15
4.1 Kesimpulan dan Saran 15

DAFTAR PUSTAKA 16

BAB I
PENDAHULUAN

1.1 Latar Belakang

Di Indonesia, guncangan kesehatan dalam rumah tangga memberikan dampak yang signifkan terhadap kondisi ekonomi rumah tangga. Salah satu biaya yang menimbulkan guncangan ini adalah naiknya pengeluaran khususnya untuk pengobatan dan perawatan (Umaroh & Listiono, 2023). Dengan naiknya pengeluaran dalam pengobatan dan perawatan, dibutuhkannya sebuah sistem proteksi finansial dalam bentuk asuransi kesehatan individu. Asuransi kesehatan individu adalah salah satu aspek penting dalam pengelolaan kekayaan dan pengurangan risiko keuangan. Sistem ini dibentuk secara khusus untuk menawarkan perlindungan finansial kepada individu terhadap peristiwa yang tidak terduga, seperti penyakit serius, keadaan darurat medis, atau kecelakaan yang memerlukan penanganan dari fasilitas kesehatan yang lebih canggih. (Heryana, 2021).

Saat ini asuransi jiwa dan kesehatan di Indonesia mengalami pertumbuhan yang signifikan dalam satu dekade terakhir, seiring dengan meningkatnya kesadaran masyarakat akan pentingnya perlindungan finansial terhadap risiko kesehatan. Berdasarkan data Otoritas Jasa Keuangan (OJK), premi asuransi jiwa dan kesehatan di Indonesia terus menunjukkan tren peningkatan, mencerminkan ekspansi industri yang pesat namun juga disertai dengan tantangan pengelolaan risiko yang semakin kompleks (Otoritas Jasa Keuangan, 2025).

Namun, salah satu isu paling penting yang mengancam keberlangsungan industri ini dalam beberapa tahun terakhir adalah adanya tren peningkatan beban klaim asuransi kesehatan individu yang bersifat eksponensial. Hal ini dapat dilihat dari akumulasi premi asuransi kesehatan pada tahun 2021 yang menunjukkan peningkatan. Akumulasi premi dalam industri asuransi kesehatan mencapai Rp. 9,53 triliun pada bulan Mei 2021, atau meningkat sebesar 7,5% dibandingkan bulan Mei tahun sebelumnya, yaitu Rp. 8,86 triliun pada tahun 2020. (Fajrini et al., 2023). Maka dari itu, dibutuhkannya peramalan klaim yang akurat sebagai fondasi dari berbagai keputusan strategis, mulai dari penetapan premi, pembentukan cadangan teknis, hingga manajemen likuiditas perusahaan. Kesalahan prediksi yang sistematis baik terlalu optimis maupun terlalu konservatif dapat berdampak langsung pada solvabilitas perusahaan dan kemampuan membayar klaim nasabah (Wuthrich & Merz, 2021).

Peramalan klaim asuransi kesehatan secara konvensional dilakukan melalui pemodelan frekuensi dan severity secara terpisah menggunakan *Generalized Linear Models* (Clemente et al., 2023; Garrido et al., 2016). Namun, pendekatan ini memiliki keterbatasan pada data deret waktu bulanan yang pendek, di mana jumlah titik data historis tidak cukup untuk estimasi parameter yang stabil. Kemunculan foundation model untuk deret waktu, khususnya Amazon Chronos (Ansari et al., 2024), membuka paradigma baru yaitu model yang telah dilatih pada ratusan ribu deret waktu dari berbagai domain dapat langsung diaplikasikan (*zero-shot*) tanpa fine-tuning, bahkan pada dataset dengan riwayat historis yang sangat terbatas seperti 19 bulan. Di sisi lain, model Prophet yang dikembangkan Meta Research (Taylor & Letham, 2017) menawarkan pendekatan yang berbeda yaitu alih-alih belajar dari ribuan deret waktu eksternal, Prophet menggunakan prior domain berupa dekomposisi tren seasonalitas yang dapat dikustomisasi secara eksplisit oleh analis. Keunggulan ini menjadikan Prophet robust terhadap perubahan tren mendadak (*structural breaks*) yang umum terjadi pada data klaim asuransi. Kombinasi Prophet yang menangkap tren deterministik dengan Chronos yang menangkap pola probabilistik dari data historis membentuk dasar dari pendekatan ensemble yang dikembangkan dalam penelitian ini.

Penelitian ini mengaplikasikan pendekatan tersebut pada dataset klaim asuransi kesehatan individu AXA Financial Indonesia yang mencakup 4.627 klaim selama periode Januari 2024–Juli 2025, dengan peserta yang tersebar di Indonesia, Singapura, dan Malaysia. Kompleksitas peramalan dalam dataset ini bertambah karena adanya heterogenitas biaya yang ekstrem antar lokasi dimana klaim Singapura memiliki rata-rata severity 3,2 kali lebih tinggi dari Indonesia dan menyumbang hampir separuh total nilai klaim bulanan, sehingga pendekatan agregat konvensional tidak memadai. Penelitian ini mengusulkan pendekatan dekomposisi berbasis lokasi geografis untuk menangani heterogenitas tersebut secara sistematis.

1.2 Rumusan Masalah

Dari latar belakang, rumusan masalah dalam penelitian ini dapat disimpulkan sebagai berikut:

1. Bagaimana cara memprediksi Claim Frequency, Claim Severity, dan Total Claim klaim asuransi kesehatan AXA Financial Indonesia untuk periode Agustus–Desember 2025?
2. Bagaimana menangani heterogenitas data klaim yang disebabkan oleh perbedaan karakteristik klaim antar lokasi geografis.

3. Model peramalan mana yang memberikan akurasi terbaik diukur dengan Mean Absolute Percentage Error (MAPE) pada data klaim asuransi kesehatan dengan karakteristik deret waktu pendek dan volatilitas tinggi?

1.3 Tujuan

Sejalan dengan rumusan masalah yang telah ditetapkan, penelitian ini memfokuskan tujuan sebagai berikut:

1. Mengembangkan model peramalan klaim asuransi kesehatan yang akurat menggunakan pendekatan dekomposisi lokasi geografis dengan strategi kuantil adaptif.
2. Mengidentifikasi dan menangani bias preprocessing akibat winsorization klaim individual terhadap deret waktu agregat bulanan.
3. Membandingkan performa berbagai pendekatan ensemble model untuk menentukan kombinasi optimal dalam konteks data asuransi dengan riwayat historis terbatas (19 bulan).

BAB II
METODOLOGI

2.1 Pemilihan Model

2.1.1 Prophet

Prophet adalah model peramalan deret waktu yang dikembangkan oleh peneliti di Meta (Facebook) yang membingkai peramalan sebagai tugas pencocokan kurva (*curve-fitting*) melalui pendekatan dekomposisi aditif. Secara matematis, model ini didekomposisi menjadi

$$y(t) = g(t) + s(t) + h(t) + \epsilon(t)$$

di mana $g(t)$ merepresentasikan fungsi tren, $s(t)$ komponen seasonalitas (musiman), dan $h(t)$ efek hari libur atau kejadian khusus (Taylor & Letham, 2017). Keunggulan utama Prophet terletak pada kemampuannya dalam menangani data yang hilang, ketahanannya terhadap *outlier*, serta performa yang konsisten pada data deret waktu bisnis dengan pola musiman. Lebih lanjut, model ini menerapkan pendekatan *"analyst-in-the-loop"* yang memungkinkan analis dengan pemahaman domain untuk menyesuaikan parameter secara intuitif. Pada penelitian ini, konfigurasi model mencakup nilai (changepoint_prior_scale = 0.05) dengan tiga *changepoint* yang ditetapkan secara manual berdasarkan analisis visual pada titik perubahan struktural data (Februari 2024, April 2024, dan Januari 2025).

2.1.2 Amazon Chronos-Bolt

Penelitian ini menggunakan Chronos-Bolt, yakni varian distilasi dari model Chronos yang dikembangkan oleh Amazon Web Services untuk *zero-shot time series forecasting*(Ansari et al., 2024). Varian ini dipilih karena rancangannya yang jauh lebih efisien secara komputasi namun tetap mampu mempertahankan performa prediktif yang sebanding dengan model utamanya. Sebagai *foundation model* berbasis arsitektur *transformer* (seperti seri T5), keluarga model Chronos secara inovatif memperlakukan deret waktu layaknya sebuah bahasa. Data deret waktu numerik ditokenisasi melalui proses penskalaan (*scaling*) dan kuantisasi (*quantization*) ke dalam kosakata diskrit, yang kemudian dipelajari oleh model menggunakan fungsi kerugian *cross-entropy*. Berkat prapelatihan (*pre-training*) yang melibatkan lebih dari 100.000 deret waktu dari berbagai domain serta pengayaan dengan data sintetis, model ini mampu menghasilkan prediksi akurat pada target data baru tanpa memerlukan tahapan *fine-tuning* (Ansari et al., 2024). Hasil prediksi dari Chronos-Bolt berupa distribusi probabilistik yang direpresentasikan melalui sembilan kuantil (0,1 hingga 0,9), sehingga memberikan fleksibilitas bagi peneliti dalam menentukan tingkat konservatisme prediksi yang paling sesuai dengan karakteristik data.

2.2 Feature Engineering

Feature Engineering dibedakan menjadi dua level, yaitu level klaim individual dan deret waktu bulanan. Level klaim individual mengeksekusi analysis temporal, demografis, dan klinis. Sedangkan, level deret waktu bulanan memiliki peran dalam mengeksekusi dalam skala waktu dengan membuat fitur lag, rolling mean, dan kalender. Pendekatan dua tingkat ini memberikan karakteristik spesifik dari dua tingkat dengan pendekatan karakteristik spesifik tingkat klaim individu dengan pola makro pergerakan klaim agregat bulanan.

2.2.1 Feature Engineering Tingkat Klaim Individual

Setelah data klaim dan data polis digabungkan, dilakukan konstruksi fitur pada dua level secara bersamaan, yaitu level klaim dan level polis, dengan tujuan memperkuat setiap rekaman klaim menggunakan informasi temporal, operasional, geografis, dan demografis yang tidak tersedia secara eksplisit dalam data mentah. Tahap ini menjadi krusial karena model forecasting deret waktu yang digunakan tidak dapat secara langsung mengekstraksi sinyal-sinyal laten tersebut dari kolom mentah, sehingga transformasi eksplisit diperlukan agar pola musiman, eksposur finansial, segmentasi risiko, maupun karakteristik demografis tertanggung dapat terwakili secara kuantitatif

dalam representasi data. Secara keseluruhan, tahap ini menghasilkan 14 fitur baru yang mencakup komponen temporal, durasi perawatan, rasio cakupan, indikator biner operasional, pengelompokan geografis, generalisasi diagnosis klinis, segmentasi usia, dan senioritas polis, yang seluruhnya akan digunakan sebagai basis agregasi pada tahap pembentukan deret waktu bulanan.

2.2.2 Deret Waktu Bulanan

Seluruh rekaman klaim diagregasi ke level bulanan untuk mengubah data individual menjadi representasi yang dapat dimodelkan secara temporal, menghasilkan tabel deret waktu 19 titik observasi yang mencakup periode Januari 2024 hingga Juli 2025 sebagai fondasi seluruh proses pemodelan. Agregasi ini menghasilkan tiga variabel target utama beserta tujuh fitur kontekstual pendukung yang merepresentasikan karakteristik komposisi klaim per bulan, di mana seluruh proses secara sengaja dilakukan sebelum winsorisasi untuk memastikan bahwa nilai target tidak mengandung bias akibat modifikasi distribusi yang diterapkan pada tahap preprocessing sebelumnya.

2.2.3 Feature Engineering Time Series

Setelah deret waktu bulanan terbentuk, dilakukan rekayasa fitur tambahan yang bersifat autoregresif dan kalender untuk memastikan bahwa model *forecasting* dapat menangkap ketergantungan temporal, dinamika perubahan jangka pendek, serta siklisitas musiman yang terkandung dalam data secara optimal. Tahap ini krusial karena model deret waktu yang digunakan tidak memiliki mekanisme bawaan untuk mengekstraksi struktur autoregresif maupun pola musiman secara otomatis dari data mentah, sehingga representasi eksplisit melalui fitur *lag*, *rolling mean*, momentum, dan *Fourier encoding* diperlukan agar informasi temporal tersebut dapat dimanfaatkan secara penuh dalam proses pelatihan, sekaligus dengan memperhatikan penerapan shift yang tepat untuk mencegah kebocoran data (*data leakage*).

2.2.4 Dekomposisi Lokasi Geografis

Lokasi	Kuantil	Index	Justifikasi
IDN	Q0,2	1	Tren penurunan stabil sehingga prediksi agresif ke bawah
SGP	Q0,4	3	Pola random walk sehingga prediksi mendekati median
MYS	Q0,3	2	Volume kecil, volatilitas moderat

Tabel 1. Dekomposisi Lokasi Geografis

Inovasi utama penelitian ini adalah dekomposisi forecasting berbasis lokasi geografis (*LocationDecomp*). Klaim Singapura memiliki rata-rata severity 3,2 kali lebih tinggi dari Indonesia dan bersifat random walk, sehingga tidak dapat dimodelkan dengan strategi yang sama. Setiap segmen diforecast menggunakan Chronos-Bolt dengan kuantil yang disesuaikan: IDN Q0,2 (tren stabil), SGP Q0,4 (random walk), dan MYS Q0,3 (volume kecil). Hasil per lokasi dijumlahkan untuk prediksi agregat, sementara Claim Severity diturunkan dari Total/Frequency — divalidasi oleh Corr(Frequency, Severity) = 0,022 (p = 0,927) yang menunjukkan pemodelan independen tidak memberikan manfaat (Garrido et al., 2016).

BAB III
HASIL PEMBAHASAN

3.1 Exploratory Data Analysis

3.1.1 Statistik Deskriptif dan Tren Deret Waktu

Gambar 1. Tren Frekuensi Klaim, Severity, dan Total Nominal Klaim (Januari 2024–Juli 2025)

Berdasarkan Gambar 1. Tren Frekusensi, Severity, dan Total Klaim (Januari–Juli 2025), dataset AXA Financial Indonesia mencakup 4.627 klaim aktif (*Status Klaim = PAID*) selama Januari 2024–Juli 2025. Analisis deret waktu bulanan pada Gambar 1 menunjukkan tiga pola penting. Pertama, *Claim Frequency* berfluktuasi antara 208–302 klaim/bulan tanpa tren penurunan yang signifikan secara statistik (p = 0,271). Kedua, *Claim Severity* rata-rata menunjukkan penurunan dari sekitar Rp 78 juta/klaim

(Januari 2024) ke Rp 55 juta/klaim (Juli 2025), namun penurunan ini tidak signifikan (p = 0,217). Ketiga, Total Nominal Klaim bulanan berkisar antara Rp 10–24 miliar dengan spike signifikan pada Januari 2024 (Rp 23,7 miliar) dan Februari 2025 (Rp 19,7 miliar) yang dapat ditelusuri ke lonjakan klaim Singapura pada bulan-bulan tersebut.

3.1.2 Analisis Tipe Perawatan dan Lama Penginapan

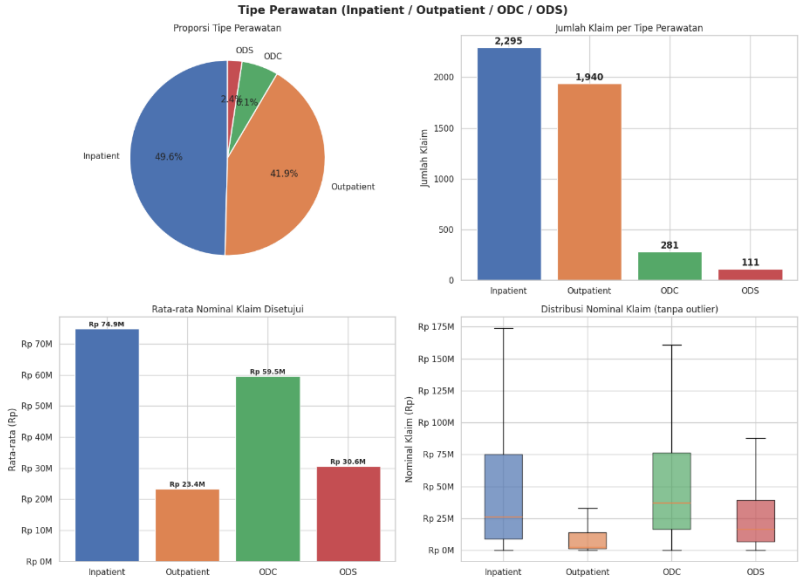

Gambar 2. Distribusi Tipe Perawatan: Proporsi, Jumlah Klaim, Rata-rata, dan Distribusi Nominal

Berdasarkan Gambar 2, distribusi tipe perawatan menunjukkan dominasi *Inpatient* (IP) dengan 2.258 klaim (49,6%) dan *Outpatient* (OP) dengan 1.940 klaim (41,9%), diikuti ODC 281 klaim (6,1%) dan ODS 111 klaim (2,4%). Meski jumlah klaim IP dan OP hampir sebanding, kontribusi nilai klaim sangat berbeda: rata-rata IP mencapai Rp 74,9 juta/klaim, 3,2x lebih tinggi dari OP (Rp 23,4 juta). Temuan menarik adalah ODC yang meskipun hanya 6,1% dari klaim memiliki rata-rata Rp 59,5 juta/klaim namun lebih tinggi dari ODS (Rp 30,6 juta) yang mengindikasikan prosedur kompleks seperti kemoterapi yang dilakukan secara rawat jalan sehari.

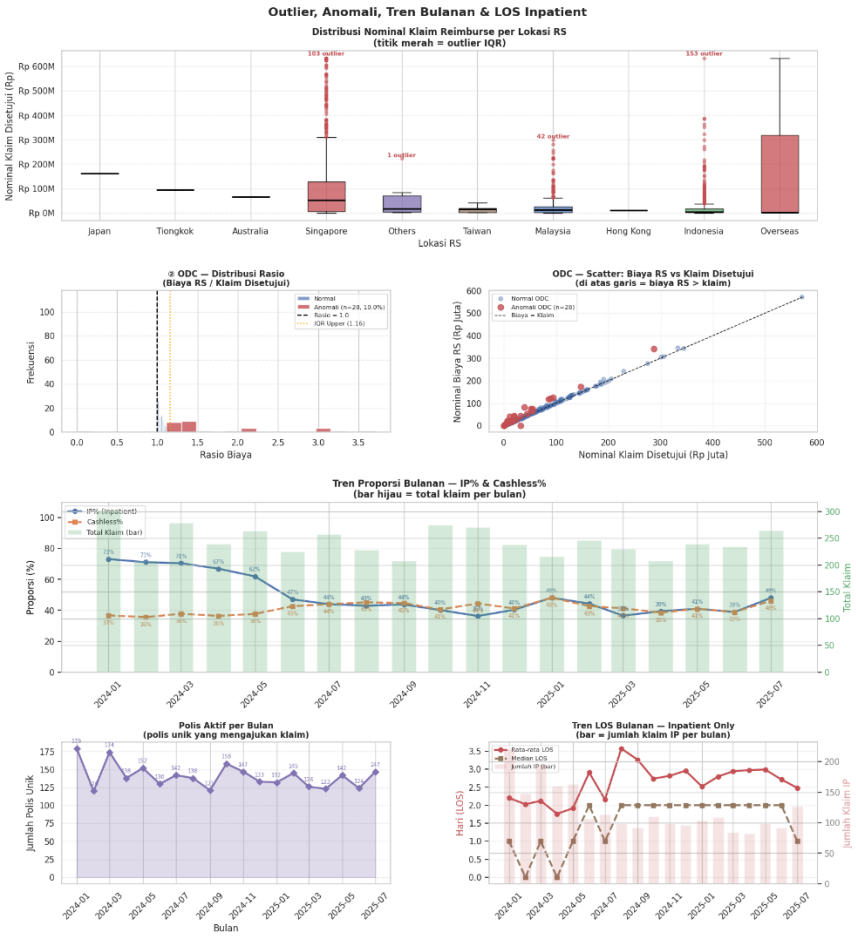

Gambar 3. Outlier, Anomali, Tren Bulanan, dan LOS

Analisis lanjutan pada Gambar 3 menyajikan empat dimensi penting secara bersamaan. Pertama, distribusi *outlier* klaim Reimburse per lokasi (subplot kiri atas) menunjukkan Singapura memiliki 103 outlier dengan nilai maksimum Rp 2.197,5 juta, sedangkan Indonesia 153 outlier dengan maksimum Rp 837,9 juta. Kedua, tren proporsi Rawat Inap dan Cashless% bulanan (subplot tengah) memperlihatkan Rawat Inap turun drastis dari 71% (Januari 2024) ke 36% (November 2024) sebelum recovery ke 48% (Juli 2025), sementara Cashless% meningkat dari 37% ke ~48%. Perubahan struktural mix perawatan inilah bukan penurunan intrinsik biaya per klaim yang menjelaskan sebagian besar penurunan Tingkat Keparahan Klaim pada Gambar 1. Ketiga, jumlah polis aktif per bulan (subplot kiri bawah) yang relatif stabil di kisaran 120–179 polis mengkonfirmasi bahwa fluktuasi klaim bukan disebabkan perubahan jumlah peserta. Keempat, Lama Rawat Inap (Length of Stay/LOS) khusus klaim Rawat Inap (subplot kanan bawah) menunjukkan rata-rata 2,0–3,6 hari dengan median stabil di 2 hari sepanjang 2025, mengindikasikan durasi perawatan yang relatif konsisten meskipun proporsi Rawat Inap mengalami perubahan.

3.1.3 Analisis Cashless vs Reimburse

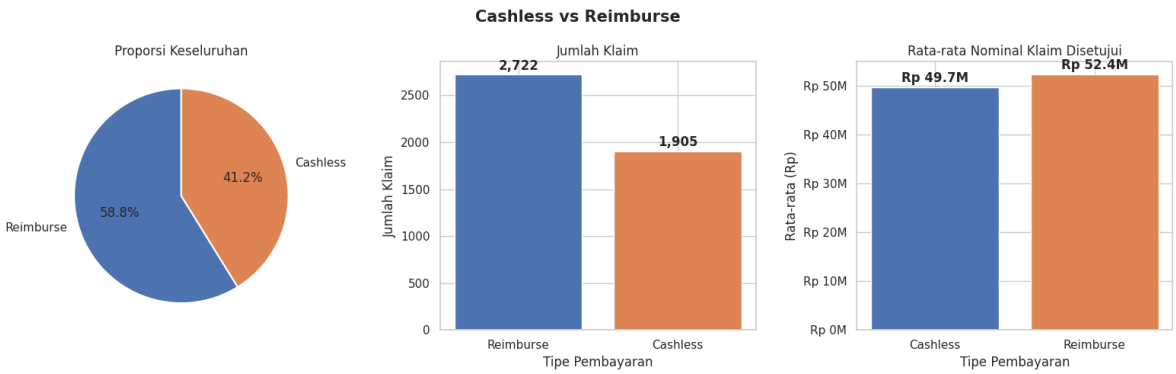

Gambar 4. Cashless vs Reimburse

Distribusi metode pembayaran menunjukkan 58,8% Reimburse (2.722 klaim) dan 41,2% Cashless (1.905 klaim). Menariknya, rata-rata nilai klaim Reimburse (Rp 58,0 juta) lebih tinggi dari Cashless (Rp 50,7 juta), mengindikasikan bahwa klaim yang diajukan secara reimburse cenderung memiliki biaya lebih besar.

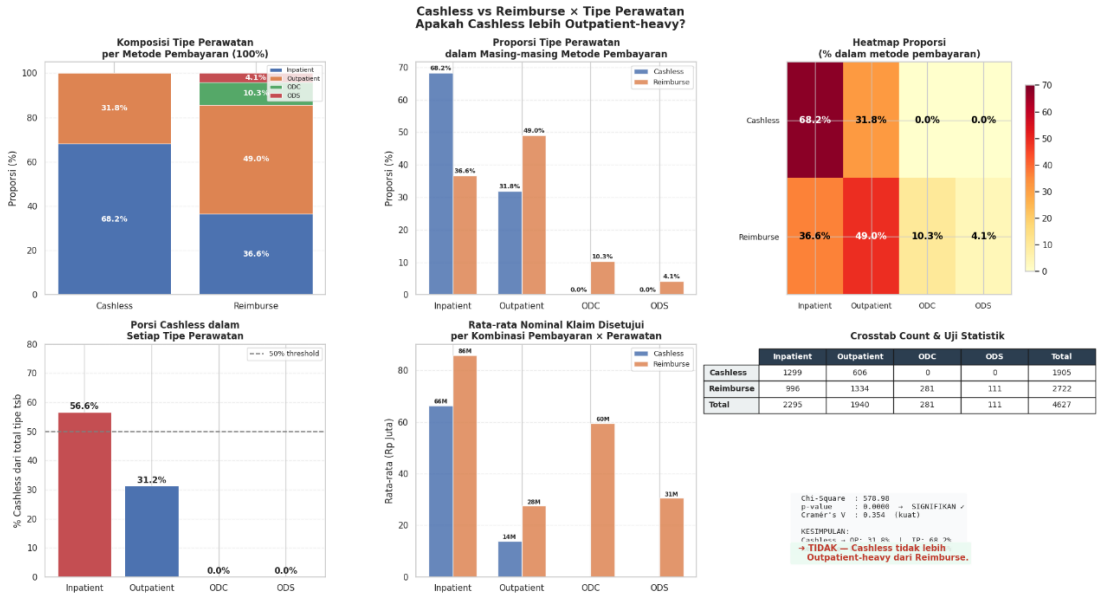

	Inpatient	Outpatient	ODC	ODS	Total
Cashless	1299	606	0	0	1905
Reimburse	996	1334	281	111	2722
Total	2295	1940	281	111	4627

Gambar 5. Cashless vs Reimburse x Tipe Perawatan

Analisis lebih lanjut menggunakan *crosstab* antara metode pembayaran dan tipe perawatan pada Gambar 5 mengungkap temuan penting. Cashless didominasi Rawat Inap (68,2%) dan Rawat Jalan (31,8%), sementara Reimburse lebih merata dengan Rawat Jalan (49,7%), Rawat Inap (35,7%), ODC (10,5%), dan ODS (4,1%). Seluruh klaim ODC dan ODS 100% menggunakan Reimburse. Dari sisi nilai klaim, Rawat Inap Reimburse rata-rata Rp 105 juta — tertinggi dari semua kombinasi, dibandingkan Rawat Inap Cashless Rp 68 juta. Hubungan ini terbukti sangat signifikan secara statistik (*Chi-Square* = 601,20, *Cramér's V* = 0,362, p < 0,0001). Kesimpulannya: Cashless tidak

lebih Rawat Jalan-berat dari Reimburse sehingga perbedaan komposisi tipe perawatan antar metode pembayaran mencerminkan kebijakan layanan, bukan preferensi peserta.

3.1.4 Analisis Lokasi Rumah Sakit

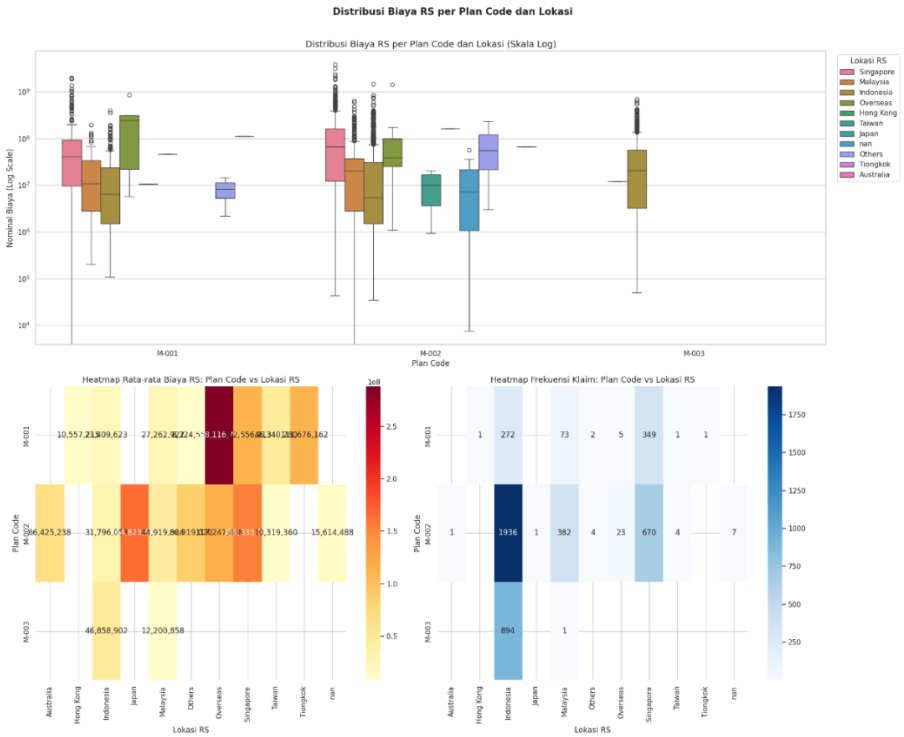

Gambar 6. Distribusi Biaya RS per Plan Code dan Lokasi

Analisis distribusi biaya RS per Plan Code dan Lokasi pada Gambar 6 mengkonfirmasi heterogenitas yang menjadi motivasi utama pendekatan dekomposisi dalam penelitian ini. Boxplot skala logaritmik (subplot atas) memperlihatkan Singapura memiliki distribusi nilai klaim tertinggi untuk semua plan dengan banyak outlier di atas Rp 500 juta, terutama pada M-001 dan M-002. Heatmap rata-rata biaya (subplot tengah) menunjukkan M-001 × Overseas sebagai sel dengan rata-rata tertinggi (Rp 288,1 juta). Heatmap frekuensi (subplot bawah) mempertegas bahwa M-002 × Indonesia (1.936 klaim) dan M-002 × Singapura (670 klaim) adalah dua sel terbesar, sementara M-003 sepenuhnya tidak memiliki klaim di Singapura yang mengindikasikan plan ini dirancang khusus untuk peserta domestik.

3.1.5 Analisis Demografi dan Diagnosis ICD

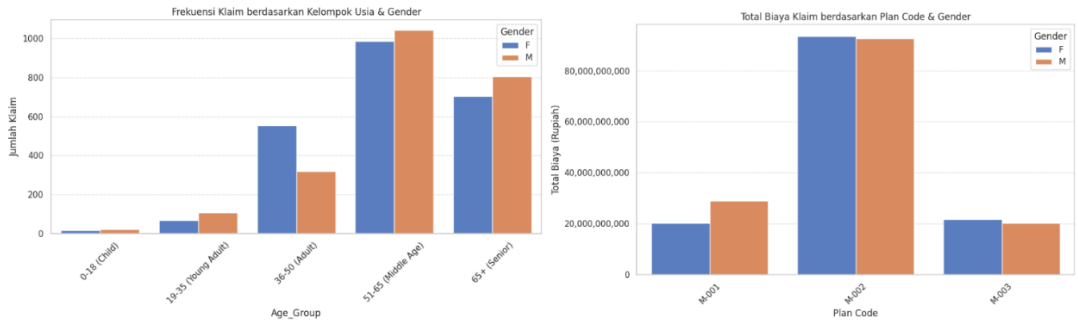

Gambar 7. Frekuensi dan Total Biaya Klaim Berdasarkan Usia, Plan Code, Gender

Distribusi frekuensi klaim berdasarkan kelompok usia dan jenis kelamin menunjukkan dominasi kelompok 51–65 tahun (~984 perempuan, ~1.040 laki-laki), dengan ketimpangan gender paling signifikan pada kelompok 36–50 tahun, perempuan (556 klaim) jauh lebih banyak dari laki-laki (319 klaim), kemungkinan didorong oleh klaim kesehatan reproduksi dan dominasi C50 (Kanker Payudara). Dari sisi total biaya per Plan Code , M-002 mendominasi dengan lebih dari Rp 90 miliar per jenis kelamin, sementara M-001 menunjukkan bias laki-laki (Rp 28,9 miliar vs Rp 20,1 miliar perempuan) yang konsisten dengan profil risiko jantung yang lebih tinggi pada laki-laki.

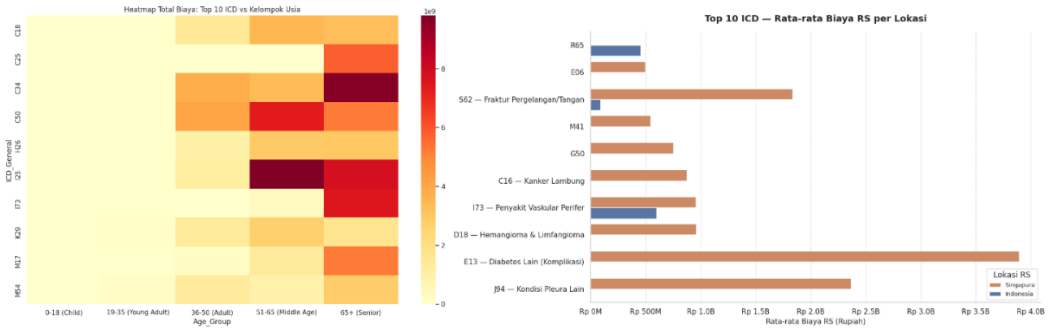

Gambar 8. Total Biaya Top 10 ICD vs Kelompok Usia dan Rata-rata biaya per Lokasi

Heatmap total biaya per ICD dan kelompok usia mengkonfirmasi pola epidemiologi yang konsisten: C34 dan C50 terkonsentrasi pada kelompok 51–65 dan 65+ tahun, sementara I25 (Jantung Koroner) menjadi titik panas terbesar pada kelompok 51–65 tahun. Analisis rata-rata biaya RS per ICD dan lokasi memperlihatkan disparitas yang konsisten — hampir setiap ICD memiliki biaya lebih tinggi di Singapura: I25 rata-rata Rp 330 juta di Singapura vs Rp 91 juta di Indonesia (selisih 3,6×), dan C18 (Kanker Kolon) mencapai Rp 184 juta vs Rp 40 juta (selisih 4,6×). Disparitas ini menjadi justifikasi empiris utama pendekatan dekomposisi lokasi (LocationDecomp) yang

diimplementasikan dalam penelitian ini.

3.2 Machine Learning Training

Pengembangan model peramalan dalam dataset menggunakan penggabungan (*ensemble*) tiga pendekatan analitis untuk menangani volatilitas data klaim asuransi kesehatan yang tinggi serta riwayat historis yang terbatas. Berdasarkan hasil pengujian, performa optimal dicapai melalui arsitektur hibrida yang dinamakan **LocationDecomposed_Triple**, yaitu gabungan struktural dari model Prophet, Chronos (pada kuantil rendah), dan model Dekomposisi Geografis.

3.2.1 Komponen Model Dasar (*Base Learners*)

Pemodelan dibangun di atas dua algoritma fundamental yang memiliki karakteristik komplementer:

- **Prophet:** Model berbasis dekomposisi aditif yang dikembangkan oleh Meta. Prophet bertugas menangkap tren makro deterministik. Model ini dikonfigurasi secara spesifik dengan parameter prioritas titik perubahan (*changepoint_prior_scale*) sebesar **0.05** pada bulan Februari 2024, April 2024, dan Januari 2025 untuk beradaptasi dengan pergeseran struktural data.
- **Amazon Chronos-Bolt:** Bertindak sebagai *foundation model zero-shot* berbasis arsitektur *transformer*. Untuk menangkap pola historis penurunan profil keparahan (*severity*), model ini diekstraksi menggunakan distribusi probabilistik pada kuantil rendah (Q0.2) guna memberikan batas bawah prediksi yang realistis terhadap data yang cenderung berfluktuasi menurun.

3.2.2 Dekomposisi Geografis (*Location Decomposed*)

Analisis data eksploratif menunjukkan bahwa klaim di Singapura menyumbang hampir setengah dari total nilai klaim bulanan meskipun volumenya kecil, menciptakan efek variansi yang persisten. Untuk mengatasi heterogenitas biaya yang ekstrem antar lokasi, model Chronos diinstruksikan dengan strategi kuantil yang adaptif per wilayah geografis:

- **Indonesia:** Prediksi menggunakan kuantil Q0.2 untuk mengakomodasi tren penurunan yang stabil.
- **Singapura:** Prediksi menggunakan kuantil Q0.4 untuk meredam volatilitas nilai klaim yang ekstrem (menyerupai *random walk*).

- **Malaysia:** Prediksi menggunakan kuantil Q0.3 untuk menyesuaikan volume klaim yang bersifat moderat.

Hasil prediksi dari ketiga wilayah ini kemudian diagregasikan kembali untuk membentuk satu nilai prediksi dekomposisi berbasis lokasi.

3.2.3 Arsitektur Final

Untuk mereduksi variansi galat (*error*) dan menghindari *overfitting* pada satu pendekatan tunggal, hasil prediksi akhir dirumuskan menggunakan metode *equal-weight ensemble*. Prediksi final dihitung dengan memberikan bobot yang setara pada masing-masing komponen pembentuknya.

$$\hat{y}_{final} = \frac{1}{3}\left(\hat{y}_{decomp} + \hat{y}_{chronos_low} + \hat{y}_{prophet}\right).$$

3.3 Hasil Prediksi

Setelah melalui serangkaian pengujian, arsitektur *ensemble* **LocationDecomposed_Triple** ditetapkan sebagai model final untuk memproyeksikan pergerakan klaim asuransi kesehatan pada periode *out-of-sample*, yakni Agustus hingga Desember 2025.

Evaluasi performa model diukur menggunakan metrik *Mean Absolute Percentage Error* (MAPE). Metrik ini mengkalkulasi seberapa besar rata-rata persentase penyimpangan antara nilai prediksi dengan nilai aktual. Pengujian akhir terhadap data uji tertutup kompetisi (*Public Leaderboard*) mencatatkan skor MAPE sebesar **4.45031**. Tingkat galat di kisaran 4,45% ini mengonfirmasi efektivitas pendekatan dekomposisi geografis dalam mengisolasi volatilitas ekstrem (khususnya anomali biaya dari Singapura), sehingga model hibrida mampu menghasilkan prediksi agregat yang terkalibrasi dengan baik. Rincian hasil proyeksi disajikan pada Tabel 2.

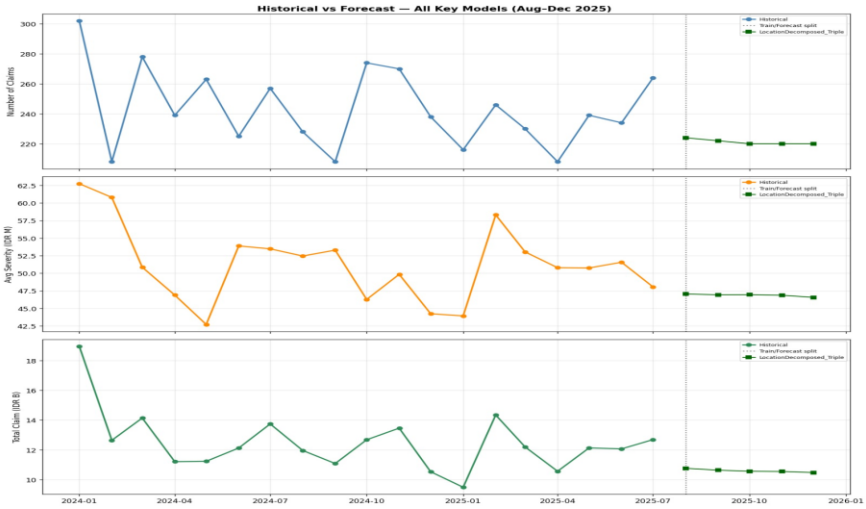

Gambar 9. Visualisasi Data Historis dan Hasil Proyeksi Model LocationDecomposed_Triple (Agustus–Desember 2025)

Tabel 2. Hasil Prediksi Klaim Asuransi (Agustus–Desember 2025)

Bulan	Frekuensi Klaim	Severitas Klaim (Juta Rp)	Total Klaim (Miliar Rp)
Agustus 2025	224	47.06	10.765
September 2025	222	46.94	10.637
Oktober 2025	220	46.95	10.565
November 2025	220	46.88	10.548
Desember 2025	220	46.57	10.477

BAB IV
PENUTUP

4.1 Kesimpulan dan Saran

Penelitian ini menunjukkan bahwa deret waktu klaim asuransi kesehatan selama periode Januari 2024 hingga Juli 2025 memiliki tren yang secara statistik menurun pada ketiga variabel target, yang tercermin dalam hasil prediksi model untuk periode Agustus hingga Desember 2025 yang juga bersifat linear ke bawah. Temuan utama penelitian ini adalah bahwa pemodelan pada level agregat tanpa mempertimbangkan heterogenitas geografis

terbukti tidak optimal, sebagaimana ditunjukkan oleh peningkatan public score MAPE secara bertahap dari Prophet (5,124) ke Chronos-Bolt (4,860), ChronosBlend (4,646), hingga akhirnya LocationDecomposed_Triple (4,473) yang mengintegrasikan dekomposisi geografis per segmen IDN, SGP, dan MYS sebagai respons atas asimetri struktural di mana klaim Singapura menyumbang 47% total nilai klaim dengan severity 3,2 kali lebih tinggi dari klaim domestik meskipun hanya berkontribusi 22% dari sisi frekuensi. Untuk penelitian selanjutnya, disarankan agar data historis yang lebih panjang digunakan untuk mengatasi keterbatasan 19 titik observasi yang menyebabkan model hanya mampu menangkap satu siklus musiman secara parsial, serta eksplorasi strategi pembobotan ensemble yang adaptif sebagai pengganti pendekatan equal-weight yang digunakan saat ini berpotensi meningkatkan akurasi prediksi lebih lanjut.

4.2 Daftar Pustaka

Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Arango, S. P., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M., & Wang, Y. (2024). Chronos: Learning the Language of Time Series. *Transactions on Machine Learning Research*, *2024*.

Clemente, C., Guerreiro, G. R., & Bravo, J. M. (2023). Gradient Boosting in Motor Insurance Claim Frequency Modelling. *Atas da Conferencia da Associacao Portuguesa de Sistemas de Informacao*, 53–69. https://doi.org/10.18803/capsi.v23.53-69

Fajrini, F., Juhazty, M. B., Latifah, N., Srisantyorini, T., Lusida, N., Romdhona, N., Dihartawan, D., & Nujulla, P. (2023). Faktor-Faktor yang Mempengaruhi Klaim Rawat Jalan Asuransi Kesehatan Peserta PT. B di Jakarta Selatan Tahun 2022. *Jurnal Kedokteran dan Kesehatan*, *19*(2), 235. https://doi.org/10.24853/jkk.19.2.235-242

Garrido, J., Genest, C., & Schulz, J. (2016). Generalized linear models for dependent frequency and severity of insurance claims. *Insurance: Mathematics and Economics*, *70*(4), 205–215. https://doi.org/10.1016/j.insmatheco.2016.06.006

Heryana, A. (2021). Asuransi Kesehatan & Managed Care [Health Insurance & Managed Care]. In *Universitas Esa Unggul*.

Otoritas Jasa Keuangan. (2025). *Statistik Perasuransian Indonesia 2024*.

Taylor, S. J., & Letham, B. (2017). *Forecasting at scale*. https://doi.org/10.7287/peerj.preprints.3190v2

Umaroh, R., & Listiono, L. (2023). Dampak Guncangan Kesehatan Terhadap Konsumsi Rumah Tangga Di Indonesia: Adakah Peran Asuransi Kesehatan Dan Kredit Mikro? *Jurnal Ekonomi Kesehatan Indonesia*, *8*(1), 11. https://doi.org/10.7454/eki.v8i1.6227

Wuthrich, M. V., & Merz, M. (2021). Statistical Foundations of Actuarial Learning and its Applications. In *SSRN Electronic Journal*. https://doi.org/10.2139/ssrn.3822407